

# Detecção de COVID-19 e Pneumonia através do uso de Inteligência Artificial em exames de Raio-X

Gabriel dos Santos Sereno  
Universidade Federal do Espírito Santo  
Vitória, Brasil  
gabriel.seren@edu.ufes.br

Joluan Luiz Arthur Zucateli Suave  
Universidade Federal do Espírito Santo  
Vitória, Brasil  
joluan.suave@edu.ufes.br

**Abstract**—Durante a pandemia do COVID-19 e o crescimento de números de casos, houve a necessidade de pesquisas para o combate e prevenção da doença. Nisso, a pesquisa efetuada é focada na detecção de COVID-19 e Pneumonia através do uso da inteligência artificial a partir dos exames de Raio-X. Foi utilizado uma CNN, a ResNet50, como classificador e exames raio-x públicos de diversas universidades como base de dados. O resultado da investigação foi satisfatório, já que a acurácia dos exames analisados pelo classificador chegaram a 90%, tornando possível a aplicação em hospitais e centros de saúde.

**Index Terms**—Classificador, COVID-19, Pneumonia, ResNet50, CNN

## I. INTRODUCTION

O uso de inteligência artificial na área de saúde está crescendo exponencialmente para auxiliar na prevenção e análise dos enfermos, sendo uma nova ferramenta para o uso médico [5].

Além disso, o início da pandemia de COVID-19 e o aumento do número de casos trouxe novos desafios à área de saúde, e uma das principais é a identificação rápida e precisa da doença.

Entretanto, os sintomas do COVID-19 são similares a outras doenças, como, por exemplo, a gripe e a pneumonia [6]. Sendo assim, isso se tornou o motivador para a investigação de um algoritmo classificador que tem a capacidade de detectar e diferenciar o COVID-19 e a pneumonia através dos exames de Raio-X.

Para a identificação e o treinamento do classificador, foi utilizado banco de imagens disponibilizadas na Internet por sites mundialmente conhecidos por suas radiográficas, tal como BimCV [1], SIRM [2] e EuroRad [3], contendo imagens de pessoas comprovadas com as doenças COVID-19 ou pneumonia, além de pessoas que não foram encontradas nenhum quadro de saúde, chegando em um total de quase 15 mil imagens.

O objetivo deste artigo é prover informações para o avanço das tecnologias utilizadas para identificação de doenças, abordando a implementação do algoritmo e de sua eficácia na classificação, mostrando sua importância no meio hospitalar.

## II. METHODS

### A. Dataset

Para classificar e treinar a base de imagens, foi utilizado rótulos para identificar quais classes os exames de Raio-X

representavam. Esses exames foram previamente classificados pelos médicos das universidades que disponibilizaram a base de imagens. Com isso, foram utilizadas 3616 imagens classificadas com COVID-19, 10192 sem nenhum quadro clínico e 1365 imagens classificadas com Pneumonia.

### B. Algoritmo ResNet50

O algoritmo proposto nesse artigo visa o rápido treinamento dos modelos e a identificação da doença com uma alta taxa de acurácia. Portanto, a utilização do algoritmo ResNet50 foi crucial para obter esses resultados, já que algoritmos que utilizam vários layers tendem a errar mais, pois o gradiente pode desaparecer em redes neurais profundas e nesses modelos o problema é corrigido, graças a técnica do bloco residual [4].

O ResNet50 é uma categoria de Rede Neural Convolutiva, sendo extremamente poderosa no processamento de imagens, já que utiliza diversos filtros para reduzir o número de pré-processamento e classificar as imagens de forma fácil e rápida [7].

Neste algoritmo, são 50 layers que efetuam a classificação, tendo um total de cerca de 24 milhões de parâmetros, sendo eles 300 mil parâmetros que podem ser treinados e 23 milhões de parâmetros que não são treinados [8].

Como mostra na Figura 1, os dados são treinados nesses layers, anterior a isso a rede conta com uma área pré-treinada, que aprende objetos não específicos, como cores, pontas, bolas e vários outros objetos, bem como características mais específicas. Dessa forma, a rede ganha mais desempenho e utiliza menos tempo para treinar, com muito menos parâmetros. Além desses layers pré-treinados, existem os layers que utilizarão o dataset das imagens e treina-los para assim, conseguir efetuar a classificação.

Para aprimorar a velocidade de treinamento, foram utilizadas duas técnicas: Early Stopping e o Model Checkpoint. A primeira técnica faz com que cada época em que o algoritmo está treinando a base seja verificado, caso o algoritmo não tenha uma relativa melhora no desempenho, essa técnica faz com que pegue a melhor combinação dos pesos e pare nesse ponto. Já a segunda técnica, grava em um arquivo os pesos da melhor combinação de parâmetros encontrada, fazendo com que não seja necessário treinar novamente o modelo, muito importante para bases grandes que necessitam de grande

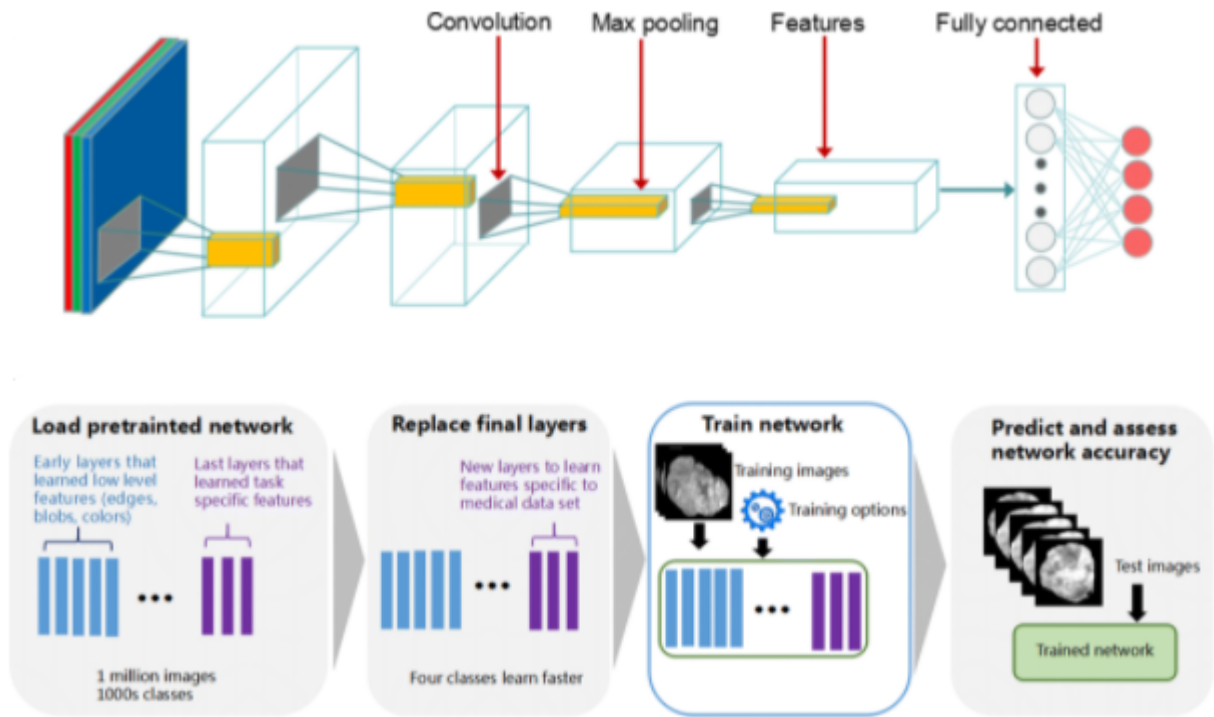


Fig. 1. Estrutura do algoritmo de ResNet50

fidelidade, pois é possível continuar o treinamento a partir do arquivo gerado, ou até mesmo iniciar a classificação.

### III. RESULTS

Após 30 minutos de treino, o classificador está pronto para identificar os exames separados para validação e teste. Nisso, após 9 épocas do algoritmo, a técnica de Early Stopping identificou que a melhor combinação atingiu a acurácia de 90%.

TABLE I

RESULTADOS DO ALGORITMO EM RELAÇÃO AS CLASSES PROPOSTAS.

	Precision	Recall	F1-score	Support
COVID	0.93	0.81	0.87	300
Normal	0.72	0.95	0.82	300
Pneumonia	0.99	0.71	0.83	200

TABLE II

INDICADORES DE PRECISÃO DO CLASSIFICADOR.

Accuracy			0.90	800
Macro AVG	0.94	0.89	0.90	800
Weighted AVG	0.93	0.91	0.90	800

Ambas Tabelas I e II mostram a eficácia, tendo baixa taxa de erros, principalmente no Recall, onde o paciente pode ser mais afetado, já que podemos verificar a porcentagem de pacientes que não foram identificados com alguma doença, um dos fatores mais importantes, pois pode salvar a vida desse paciente.

A Figura 2 mostra a taxa de acurácia ao decorrer das épocas treinadas. O valor em azul é a acurácia a partir dos dados de teste e o valor em vermelho é a taxa de acurácia a partir dos dados de treino. A partir dessa informação, é possível verificar a evolução do classificador e também a parada do Early Stopping, que verificou que após 2 épocas o algoritmo não obteve melhora e determinou a parada do treinamento.




Fig. 2. Acurácia vs Val-Acurácia

A Figura 3 mostra a taxa de loss do classificador, quanto menor o valor de loss, melhor o modelo. A linha vermelha é a taxa de loss na base de treinamento e a azul é na base de testes. Se verificarmos em ambos os gráficos, as taxas de loss

e da acurácia foram melhores na época 6 que foi seleccionada pelo classificador.




Fig. 3. Loss vs Val-Loss

Com o classificador treinado, testamos uma imagem, Figura 4, que não foi utilizada no processo de aprendizado para verificar se o classificador está classificando corretamente e obtivemos resultados excelentes. Esse exame de Raio-X foi detectado no paciente a Pneumonia pelo médico responsável, já para o classificador os resultados foram:

- 3,5% de chance de ser COVID-19;
- 0% de chance de ser um paciente sem quadro clínico;
- 96,5% de chance de ser pneumonia.




Fig. 4. Imagem de Raio-X que foi identificado COVID-19.

A Figura 5 mostra o exame Raio-X de uma pessoa identificada com a COVID-19, esta imagem não passou pelo conjunto de treino, e quando testada obtivemos os resultados:

- 97,8% de chance de ser COVID-19;
- 0% de chance de ser um paciente sem quadro clínico;
- 2,2% de chance de ser pneumonia.




Fig. 5. Imagem de Raio-X que foi identificado COVID-19.

Por fim, a Figura 6 mostra o exame de uma pessoa que não foi identificada nenhum quadro clínico e quando testada obtivemos os resultados:

- 9% de chance de ser COVID-19;
- 90% de chance de ser um paciente sem quadro clínico;
- 1% de chance de ser pneumonia.




Fig. 6. Imagem de Raio-X que não foi identificado quadro clínico.

Com esses resultados, é possível de ajudar consistentemente o médico com pré-indicação dos exames e com isso, priorizar os atendimentos conforme a classificação da Inteligência Artificial.

#### IV. CONCLUSION

Portanto, a inteligência artificial criada foi eficaz em identificar as doenças propostas, bem como o estado normal do

paciente. Dessa forma, o classificador pode ser uma ferramenta auxiliar para o médico de linha de frente no combate do coronavírus, podendo utilizar como um pré-classificador da doença e ajudar na rapidez da identificação do paciente que há suspeita do Coronavírus e Pneumonia.

Essa afirmação é possível ser observada pelos gráficos e informações fornecidas que comprovam a eficácia do algoritmo. Ademais, essas informações são base para determinar a segurança em que os resultados classificados pela Inteligência Artificial, tem baixo erro e podem ser a chave para salvar vidas.

Para a construção desse classificador, não houve nenhum custo para a realização do experimento. Logo, empresas voltadas para a área de saúde poderiam investir em identificação automatizada de doenças através de exames, não só de Raio-X, mas também na análise de dados do paciente para potencializar a prevenção da saúde do paciente.

Por fim, esse artigo foi importante para consolidar que a inteligência artificial pode beneficiar a área hospitalar sem grandes investimentos, tanto monetário, quanto computacional. Além disso, as doenças identificadas no artigo podem ser classificadas de maneira satisfatória por meio da Rede Neural Convolucional. Para possíveis contribuições futuras seriam implementar em um hospital o algoritmo criado para trabalhar com os exames realizados diariamente do hospital e verificar como a inteligência artificial afetou o trabalho dos agentes de saúde; outra contribuição seria de acrescentar outras categorias de doença, para verificar se a Rede Neural Convolucional consegue identificar diversas categorias de doenças com grande taxa de acurácia.

## REFERENCES

- [1] BimCV, “BIMCV-COVID19”. Disponível em: <https://bimcv.cipf.es/bimcv-projects/bimcv-covid19/>. Acessado em: 16 de setembro de 2021.
- [2] SIRM, “COVID-19”. Disponível em: <https://eurorad.org>. Acessado em: 16 de setembro de 2021.
- [3] EuroRAD, “COVID-19”. Disponível em: <https://eurorad.org>. Acessado em: 16 de setembro de 2021.
- [4] Y. Bengio, P. Simard, and P. Frasconi. Learning long-term dependencies with gradient descent is difficult. *IEEE Transactions on Neural Networks*, 5(2):157–166, 1994.
- [5] Javed, A.R., Sarwar, M.U., Beg, M.O., Asim, M., Baker, T., Tawfk, H.: A collaborative healthcare framework for shared healthcare plan with ambient intelligence. *Human-Centric Comput. Inform. Sci.* 10(1), 1–21 (2020)
- [6] Bhattacharya, S., Maddikunta, P.K.R., Pham, Q.V., Gadekallu, T.R., Chowdhary, C.L., Alazab, M., Piran, M.J., et al.: Deep learning and medical image processing for coronavirus (covid-19) pandemic: a survey. *Sustain. Cities Soc.* 65, 102589 (2021)
- [7] K. Simonyan and A. Zisserman. Very deep convolutional networks for large-scale image recognition. In *ICLR*, 2015.
- [8] A. Krizhevsky, I. Sutskever, and G. Hinton. Imagenet classification with deep convolutional neural networks. In *NIPS*, 2012.