

Análise dos algoritmos PSO e GA em conjunto com Neural Network

Gabriel dos Santos Sereno¹

Abstract

Com o aumento exponencial da Inteligência Artificial e principalmente do uso de redes neurais, este artigo visa analisar a aplicação de algoritmos metaheurísticos para a otimização do algoritmo de rede neural. Para isso, foi utilizado duas metaheurísticas: Genetic Algorithm e PSO, ambos em conjunto com Neural Network em bases de estudos, como: Wine, Breast Cancer e Iris para efetuar o benchmark entre as soluções. De fato, os resultados foram satisfatórios e potencializados com os algoritmos metaheurísticos, que no que lhe concerne, procuram bons pesos com pouco uso computacional, achando rapidamente os pesos ideais para uma boa classificação nas bases.

Keywords: Neural Network, PSO, Genetic Algorithm, *Classificação, Metaheurísticas*

1. Introdução

Atualmente os algoritmos de Inteligência Artificial estão crescendo exponencialmente em popularidade no meio acadêmico e também no meio empresarial. Esse crescimento é devido a grande eficácia na área de classificação e cluster-
5 ização. Por isso, esse relatório tem o foco de mostrar um comparativo entre PSO e o Genetic Algorithm com foco nas redes neurais.

As bases escolhidas para testar os algoritmos em conjunto com a rede neural, foram as bases: Wine, Breast Cancer e Iris.

¹Aluno do curso de mestrado com ênfase em Inteligência Artificial na Universidade Federal do Espírito Santo

2. Metaheurísticas

10 O foco do relatório é voltado inteiramente na análise do poder das meta-heurísticas em conjunto com as redes neurais, bem como na assertividade.

2.1. Genetic Algorithm

O algoritmo *Genetic Algorithm* visa procurar os melhores valores através da busca genética, similar ao sistema biológico humano, onde utiliza mutações,
15 troca de genes e outras características importantes desse algoritmo. A principal ideia do algoritmo *Genetic Algorithm* é utilizar as melhores combinações para construir novas combinações com pequena diferenciação, visando aprimorar a cada geração o resultado obtido.

Para isso, o método de criação de dados faz uma população para iniciar os
20 testes. Nisso, é verificado qual de todas as combinações são as melhores para iniciar o elitismo e a mutação para gerar novas combinações de classificadores e novamente fazer mais uma etapa da criação da população. No artigo, para encerrar os ciclos a procura do melhor classificador, foi pelo método de parada após 120 segundos.

25 Como o algoritmo *Genetic Algorithm* pode gerar combinações que já foram testadas e também com alto número de combinações por ciclo, tendendo a gastar várias horas até determinar o melhor classificador encontrado.

2.2. PSO

Na ciência da computação, PSO (Particle Swarm Optimization) é um método
30 computacional que otimiza iterativamente tentando melhorar a solução através de partículas que se movem nesse espaço através de uma simples fórmula matemática utilizando a posição e a velocidade dessas partículas. Cada partícula se move influenciada pelo seu melhor local e também posicionado para o melhor global. Dessa forma, as partículas tendem a procurar sempre o melhor local, sem dificuldades em sair de mínimos locais.
35

3. Implementação

Os projetos que utilizaram PSO e *Genetic Algorithm*, além do algoritmo de redes neurais, foram utilizados as bibliotecas respectivamente: Pyswarm, PyGAD e PyGAD na versão *Neural Network*. Nesse caso, foi necessário ajustar os hiperparâmetros para ajustar em cada base, principalmente a quantidade de entradas, quantidade de camadas, classes e entre vários outros.

A seguir, os hiperparâmetros utilizados nos projetos:

Hiperparâmetros	Valores
Layers	3
Nº Hidden	60 neurônios / 100 neurônios
PSO	100 Partículas
GA	500 Gerações
Iterações	1000 (PSO) / 500 (NN)
Ativação	Tahn (PSO) / Relu (NN)
Fitness Function	$f = y / y_{pred}$

Table 1: Principais hiperparâmetros em ambos algoritmos

Com esses hiperparâmetros, foi possível aplicar os algoritmos nas bases utilizadas no projeto.

4. Comparativo entre os resultados

Para realizar o comparativo, cada algoritmo foi repetido por 10 vezes para gerar resultados sólidos. Com isso, foram gerados os seguintes resultados:

4.1. Iris

A base *Iris* é uma das mais famosas bases em comparação com as demais, contendo 150 linhas com 4 colunas, além de ter 3 classes que torna o trabalho do classificador fácil. Os resultados dos classificadores utilizados estão na tabela a seguir:

Algoritmos	Resultados
PSO	100%
GA	100%

Table 2: Resultados dos algoritmos na base Iris

Os algoritmos apresentaram excelentes e consistentes resultados devido ao alto poder de classificação da rede neural, fazendo com que o modelo se ajuste
55 perfeitamente na base. Sendo assim, ambos obtiveram 100% de precisão. A velocidade de ambos os algoritmos foram quase instantâneas, cumprindo com o requisito de eficiência e eficácia.

4.2. *Wine*

A base *Wine* contem apenas 3 classes e cerca de 180 linhas com 13 colunas.
60 A seguir, as tabelas com os resultados encontrados:

Algoritmos	Resultados
PSO	100%
GA	69%

Table 3: Resultados dos algoritmos na base Wine

Novamente o PSO conseguiu um resultado perfeito na classificação da base Wine, entretanto demorou cerca de 5 minutos para chegar a perfeição na classificação. Entretanto, o algoritmo genético (GA) teve uma porcentagem bastante reduzida, cerca de 69% com a execução bem mais rápida em comparação ao
65 PSO. Provavelmente o algoritmo teve maior dificuldade por ter maior número de características.

4.3. *Breast Cancer*

A base *Breast Cancer* contém 2 classes apenas, significando se o paciente possui ou não o câncer. Além disso, é uma base mediana, contendo 569 linhas
70 com 30 colunas. Com essas características, os algoritmos tendem a ter um excelente desempenho, pois contem um bom número de linhas e colunas. O

trabalho torna-se mais fácil ao classificar apenas duas classes. Esses resultados encontrados estão na tabela a seguir:

Algoritmos	Resultados
PSO	100%
GA	97%

Table 4: Resultados dos algoritmos na base Breast Cancer

Novamente o PSO achou o melhor resultado, entretanto necessitou cerca
75 de 10 minutos para achar. Dessa forma, não cumprindo com a eficiência em
comparação com o algoritmo genético (GA), que chegou a encontrar valores pela
metade do tempo e com pouca perda de acurácia, cerca de 97%. Dessa forma,
o algoritmo genético pode ser a melhor escolha para datasets que precisam de
rapidez e menos uso computacional em comparação ao PSO.

80 4.4. Comparação da base Iris entre backpropagation e GA/PSO

Para realizar essa comparação, foi utilizado um notebook disponibilizado no
Kaggle [1] e mostra quão diferente pode ser o resultado e a sua velocidade.

Com isso, o algoritmo com backpropagation em comparação ao GA/PSO
obteve:

Algoritmos	Resultados
Backpropagation	94%
GA/PSO	100%

Table 5: Resultados do Backpropagation em comparação ao GA/PSO

85 Gráfico que representa Custo x Iteração:




Figure 1: Gráfico que mostra o Custo x Interação na base Iris.

Portanto, o resultado foi 6% inferior às metaheurísticas e utilizou 1 hora de treinamento para chegar nesse resultado. Nisso mostra a diferença e o poder dos algoritmos diante do backpropagation, sendo uma grande alternativa para melhorar a eficiência da classificação.

90 5. Conclusões

Trabalhar com comparações é essencial para achar o melhor resultado e o classificador que encaixa melhor a um determinado problema. Com os testes feitos desse artigo, foi possível observar a diferença das metaheurísticas com as redes neurais, principalmente no uso do tempo e computacional.

95 Ademais, as metaheurísticas se demonstraram poderosas em aprimorar os resultados das redes neurais, além de ser facilmente implementados e altamente customizáveis. Diante disso, deve-se analisar o uso computacional se é viável ou não em um projeto que visa classificar rapidamente bases de dados.

Esse trabalho contribuiu com o aprofundamento das técnicas de metaheurística
 100 e de testes, possibilitando o aprendizado mais palpável, na prática. As descobertas ao implementar empiricamente a teoria foram fundamentais para consolidar e tornar base para situações reais. Por isso, para contribuições futuras, sugiro

a utilização de outras metaheurísticas.

References

- ¹⁰⁵ [1] Kaggle, Iris data set classification using neural network (2018).
URL <https://www.kaggle.com/azzion/iris-data-set-classification-using-neural-network>

- Slides, artigos e notas transmitidas em aula das disciplinas tutoradas pelo professor.